

Выявление основных уравнений из данных путем разреженной идентификации нелинейных динамических систем

Стивен Л. Брантон , Джошуа Л. Проктор и Дж. Натан Куц [Информация об авторах и их принадлежность](#)

Под редакцией Уильяма Биалека, Принстонский университет, Принстон, Нью-Джерси, и одобрено 1 марта 2016 г. (получено для рецензирования 31 августа 2015 г.)

28 марта 2016 г. 113 (15) 3932 - 3937 <https://doi.org/10.1073/pnas.1517384113>

 250 025 | 2 612

   PDF/EPUB

Значение

Понимание динамических ограничений и балансов в природе способствовало быстрому развитию знаний и позволило технологиям, включая самолеты, двигатели внутреннего сгорания, спутники и электроэнергию. Эта работа разрабатывает новую структуру для обнаружения управляющих уравнений, лежащих в основе динамической системы, просто из измерений данных, используя достижения в методах разреженности и машинном обучении. Полученные модели являются экономичными, уравнивая сложность модели с описательной способностью, избегая при этом переобучения. Существует множество критических проблем, управляемых данными, таких как понимание познания из нейронных записей, выведение климатических моделей, определение стабильности финансовых рынков, прогнозирование и подавление распространения болезней и контроль турбулентности для более экологичного транспорта и энергии. С обильными данными и неуловимыми законами, управляемое данными открытие динамики будет продолжать играть важную роль в этих усилиях.

Абстрактный

Извлечение управляющих уравнений из данных является центральной проблемой во многих различных областях науки и техники. Данных много, тогда как модели часто остаются неуловимыми, как в климатологии, нейробиологии, экологии, финансах и эпидемиологии, и это лишь несколько примеров. В этой работе мы объединяем методы, способствующие разреженности, и машинное обучение с нелинейными динамическими системами для обнаружения управляющих

PDF

Помощь

уравнений из зашумленных данных измерений. Единственное предположение о структуре модели заключается в том, что существует только несколько важных членов, которые управляют динамикой, так что уравнения разрежены в пространстве возможных функций; это предположение справедливо для многих физических систем в подходящем базисе. В частности, мы используем разреженную регрессию для определения наименьшего количества членов в динамических управляющих уравнениях, необходимых для точного представления данных. Это приводит к экономным моделям, которые уравнивают точность со сложностью модели, чтобы избежать переобучения. Мы демонстрируем алгоритм для широкого круга задач, от простых канонических систем, включая линейные и нелинейные осцилляторы и хаотическую систему Лоренца, до вихревого потока жидкости за препятствием. Пример жидкости иллюстрирует способность этого метода обнаруживать базовую динамику системы, на решение которой экспертам сообщества потребовалось почти 30 лет. Мы также показываем, что этот метод обобщается на параметризованные системы и системы, которые изменяются во времени или имеют внешнее воздействие.

Подпишитесь на оповещения PNAS.

Получайте оповещения о новых статьях или получайте оповещения при цитировании статьи.

УПРАВЛЕНИЕ ОПОВЕЩЕНИЯМИ

Достижения в области машинного обучения ([1](#)) и науки о данных ([2](#)) обещали возрождение в анализе и понимании сложных данных, извлечении закономерностей из огромных мультимодальных данных, которые находятся за пределами способности человека понять. Однако, несмотря на быстрое развитие инструментов для понимания статических данных на основе статистических взаимосвязей, наблюдается медленный прогресс в извлечении физических моделей динамических процессов из больших данных. Это ограничило способность моделей науки о данных экстраполировать динамику за пределы аттрактора, где они были отобраны и построены.

Можно провести аналогию с открытиями Кеплера и Ньютона. Кеплер, обладая самыми обширными и точными планетарными данными той эпохи, разработал модель движения планет, основанную на данных, что привело к его знаменитым эллиптическим орбитам. Однако это был взгляд на мир, основанный на аттракторах, и он не объяснял фундаментальные динамические соотношения, которые приводят к планетарным орбитам, и не давал модели того, как эти тела реагируют при возмущении. Ньютон, напротив, открыл динамическое соотношение между импульсом и энергией, которое описывало основные процессы, ответственные за эти эллиптические орбиты. Эту динамическую модель можно обобщить для прогнозирования поведения в режимах, когда не было собрано никаких данных. Модель Ньютона оказалась удивительно

надежной для инженерного проектирования, что позволило посадить космический корабль на Луну, что было бы невозможно при использовании только модели Кеплера.

Основополагающий прорыв Бонгарда и Липсона ([3](#)) и Шмидта и Липсона ([4](#)) привел к новому подходу к определению базовой структуры нелинейной динамической системы из данных. Этот метод использует символическую регрессию [т. е. генетическое программирование ([5](#))] для поиска нелинейных дифференциальных уравнений и уравнивает сложность модели, измеряемую количеством членов, с точностью модели. Полученная идентификация модели реализует долгожданную цель физических и инженерных сообществ по обнаружению динамических систем из данных. Однако символическая регрессия является дорогостоящей, плохо масштабируется для больших интересующих систем и может быть склонна к переобучению, если не принять мер для явного уравнивания сложности модели с предсказательной силой. В работе [4](#) фронт Парето используется для поиска экономичных моделей. Существуют и другие методы, которые решают различные аспекты проблемы обнаружения динамических систем. К ним относятся методы обнаружения управляющих уравнений из данных временных рядов ([6](#)), моделирование без уравнений ([7](#)), эмпирическое динамическое моделирование ([8](#) , [9](#)), моделирование эмерджентного поведения ([10](#)) и автоматизированный вывод динамики ([11–13](#)); ссылка [12](#) содержит превосходный обзор.

Разреженная идентификация нелинейной динамики (SINDy)

В этой работе мы переосмысливаем проблему обнаружения динамических систем с точки зрения разреженной регрессии ([14–16](#)) и сжатого зондирования ([17–22](#)). В частности, мы используем тот факт, что большинство физических систем имеют только несколько релевантных терминов, которые определяют динамику, делая управляющие уравнения разреженными в многомерном нелинейном функциональном пространстве. Сочетание методов разреженности в динамических системах появилось совсем недавно ([23–30](#)) . [Здесь](#) мы рассматриваем динамические системы ([31](#)) вида

$$\frac{d}{dt}\mathbf{x}(t) = \mathbf{f}(\mathbf{x}(t)). \quad [1]$$

Вектор $\mathbf{x}(t) \in \mathbb{R}^n$ обозначает состояние системы в момент времени t , а функция $\mathbf{f}(\mathbf{x}(t))$ представляет динамические ограничения, которые определяют уравнения движения системы, такие как второй закон Ньютона. Позже динамика будет обобщена, чтобы включить параметризацию, зависимость от времени и принуждение.

Ключевым наблюдением является то, что для многих интересующих нас систем функция $\mathbf{f}$ состоит всего из нескольких членов, что делает его разреженным в пространстве возможных функций. Недавние достижения в сжатом измерении и разреженной регрессии делают эту точку зрения на разреженность благоприятной, поскольку теперь можно определить, какие члены правой стороны не равны нулю, не выполняя комбинаторно неразрешимый поиск методом грубой силы. Это гарантирует, что

разреженное решение будет найдено с высокой вероятностью с использованием выпуклых методов, которые масштабируются до больших задач выгодно с законом Мура. Получающаяся в результате разреженная идентификация модели по своей сути уравнивает сложность модели (т. е. разреженность динамики правой стороны) с точностью, избегая переобучения модели данным. Ван и др. ([23](#)) использовали сжатое измерение для определения нелинейной динамики и прогнозирования катастроф; здесь мы выступаем за использование разреженной регрессии для сглаживания шума.

Чтобы определить функцию f из данных мы собираем историю состояния во времени $\mathbf{x}(t)$ и либо измерить производную $\dot{\mathbf{x}}(t)$ или аппроксимировать его численно из $\mathbf{x}(t)$. Данные выбираются в несколько моментов времени $t_1, t_2, \dots, t_m$ и организованы в две матрицы:

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}^T(t_1) \\ \mathbf{x}^T(t_2) \\ \vdots \\ \mathbf{x}^T(t_m) \end{bmatrix} = \begin{array}{c} \xrightarrow{\text{state}} \\ \begin{bmatrix} x_1(t_1) & x_2(t_1) & \cdots & x_n(t_1) \\ x_1(t_2) & x_2(t_2) & \cdots & x_n(t_2) \\ \vdots & \vdots & \ddots & \vdots \\ x_1(t_m) & x_2(t_m) & \cdots & x_n(t_m) \end{bmatrix} \\ \downarrow \text{time} \end{array}$$

$$\dot{\mathbf{X}} = \begin{bmatrix} \dot{\mathbf{x}}^T(t_1) \\ \dot{\mathbf{x}}^T(t_2) \\ \vdots \\ \dot{\mathbf{x}}^T(t_m) \end{bmatrix} = \begin{bmatrix} \dot{x}_1(t_1) & \dot{x}_2(t_1) & \cdots & \dot{x}_n(t_1) \\ \dot{x}_1(t_2) & \dot{x}_2(t_2) & \cdots & \dot{x}_n(t_2) \\ \vdots & \vdots & \ddots & \vdots \\ \dot{x}_1(t_m) & \dot{x}_2(t_m) & \cdots & \dot{x}_n(t_m) \end{bmatrix}.$$

Далее мы создаем библиотеку $\Theta(\mathbf{X})$ состоящий из кандидатов на нелинейные функции столбцов $\mathbf{X}$. Например, $\Theta(\mathbf{X})$ может состоять из постоянных, полиномиальных и тригонометрических членов:

$$\Theta(\mathbf{X}) = \begin{bmatrix} 1 & \mathbf{X} & \mathbf{X}^{P_2} & \mathbf{X}^{P_3} & \cdots & \sin(\mathbf{X}) & \cos(\mathbf{X}) & \cdots \end{bmatrix}. \quad [2]$$

Здесь высшие полиномы обозначаются как $\mathbf{X}^{P_2}, \mathbf{X}^{P_3}$, и т.д., где $\mathbf{X}^{P_2}$ обозначает квадратичные нелинейности в состоянии $\mathbf{x}$:

$$\mathbf{X}^{P_2} = \begin{bmatrix} x_1^2(t_1) & x_1(t_1)x_2(t_1) & \cdots & x_2^2(t_1) & \cdots & x_n^2(t_1) \\ x_1^2(t_2) & x_1(t_2)x_2(t_2) & \cdots & x_2^2(t_2) & \cdots & x_n^2(t_2) \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ x_1^2(t_m) & x_1(t_m)x_2(t_m) & \cdots & x_2^2(t_m) & \cdots & x_n^2(t_m) \end{bmatrix}.$$

Каждый столбец $\Theta(\mathbf{X})$ представляет собой функцию-кандидата для правой стороны [уравнения 1](#). Существует огромная свобода в выборе записей в этой матрице нелинейностей. Поскольку мы считаем, что только несколько из этих нелинейностей активны в каждой строке $\mathbf{f}$, мы можем поставить задачу разреженной регрессии для определения разреженных векторов коэффициентов $\Xi = [\xi_1 \ \xi_2 \ \cdots \ \xi_n]$ которые определяют, какие нелинейности активны:


$$\dot{\mathbf{X}} = \Theta(\mathbf{X})\Xi. \quad [3]$$

Это показано на [рис. 1](#). Каждый столбец ξ_k из Ξ представляет собой разреженный вектор коэффициентов, определяющих, какие члены активны в правой части одного из уравнений строки $\dot{\mathbf{x}}_k = \mathbf{f}_k(\mathbf{x})$ в [уравнении 1](#). После того, как Ξ определено, модель каждой строки основных уравнений может быть построена следующим образом:

$$\dot{\mathbf{x}}_k = \mathbf{f}_k(\mathbf{x}) = \Theta(\mathbf{x}^T) \xi_k. \quad [4]$$

Обратите внимание, что $\Theta(\mathbf{x}^T)$ представляет собой вектор символических функций элементов $\mathbf{x}$, в отличие от $\Theta(\mathbf{X})$, которая является матрицей данных. Таким образом,

$$\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}) = \Xi^T (\Theta(\mathbf{x}^T))^T. \quad [5]$$



Каждый столбец [уравнения 3](#) требует отдельной оптимизации для нахождения разреженного вектора коэффициентов ξ_k для уравнения строки k . Мы также можем нормализовать столбцы $\Theta(\mathbf{X})$, особенно когда записи $\mathbf{X}$ малы, как обсуждается в [Приложении SI](#).

Для примеров в этой статье матрица $\Theta(\mathbf{X})$ имеет размер $m \times p$, где p — число функций-кандидатов, а $m \gg p$ поскольку выборка данных больше, чем функций; это возможно в ограниченном базисе, таком как полиномиальный базис в [уравнении 2](#). На практике может быть полезно протестировать много различных базисов функций и использовать разреженность и точность полученной модели в качестве диагностического инструмента

для определения правильного базиса для представления динамики. В [Приложении SI](#), [Приложении B](#), рассматриваются два примера, в которых алгоритм разреженной идентификации терпит неудачу, поскольку динамика не является разреженной в выбранном базисе.

Реально, часто только $\mathbf{X}$ доступен, и $\dot{\mathbf{X}}$ должны быть приближены численно, как во всех примерах непрерывного времени ниже. Таким образом, $\mathbf{X}$ и $\dot{\mathbf{X}}$ загрязнены шумом, поэтому [уравнение 3](#) не выполняется точно. Вместо этого,

$$\dot{\mathbf{X}} = \Theta(\mathbf{X})\Xi + \eta\mathbf{Z}, \quad [6]$$

где $\mathbf{Z}$ моделируется как матрица независимых одинаково распределенных гауссовых элементов с нулевым средним и величиной шума η . Таким образом, мы ищем разреженное решение для переопределенной системы с шумом. Наименьший абсолютный оператор сжатия и выбора (LASSO) ([14](#), [15](#)) является ℓ_1 -регуляризованная регрессия, которая способствует разреженности и хорошо работает с этим типом данных. Однако она может быть вычислительно затратной для очень больших наборов данных. Альтернатива, основанная на последовательных пороговых наименьших квадратах, представлена в Коде 1 в [Приложении SI](#).

В зависимости от шума может потребоваться фильтрация $\mathbf{X}$ и $\dot{\mathbf{X}}$ прежде чем решить для Ξ . Во многих примерах ниже только данные $\mathbf{X}$ доступны, и $\dot{\mathbf{X}}$ получаются путем дифференциации. Чтобы противодействовать ошибке дифференциации, мы используем регуляризацию полной вариации ([32](#)), чтобы очистить производную ([33](#)). Это работает достаточно хорошо, когда только данные о состоянии $\mathbf{X}$ доступны, как показано на системе Лоренца ([Приложение SI, Рис. S7](#)). В качестве альтернативы, данные $\mathbf{X}$ и $\dot{\mathbf{X}}$ могут быть отфильтрованы, например, с использованием оптимального жесткого порога для сингулярных значений, описанного в ссылке [34](#). Нечувствительность к шуму является важной особенностью алгоритма, который определяет динамику из данных ([11](#) – [13](#)).

Часто интересующая физическая система может быть естественным образом представлена частным дифференциальным уравнением (PDE) с несколькими пространственными переменными. Если данные собираются из числовой дискретизации или из экспериментальных измерений на пространственной сетке, то размерность состояния n может быть неоправданно большой. Например, в динамике жидкости даже простые 2D и 3D потоки могут потребовать от десятков тысяч до миллиардов переменных для представления дискретизированной системы. Предлагаемый метод плохо подходит для большой размерности состояния n из-за факториального роста $\Theta(n)$ и потому что каждое из n уравнений строки в [уравнении 4](#) требует отдельной оптимизации. К счастью, многие интересующие нас многомерные системы развиваются на многообразии или аттракторе низкой размерности, которые хорошо аппроксимируются с использованием базиса низкого ранга Ψ ([35](#), [36](#)). Например, если данные $\mathbf{X}$ собраны для высокоразмерной системы, как в [уравнении 2](#), можно получить

приближение низкого ранга, используя методы снижения размерности, такие как правильное ортогональное разложение (POD) ([35](#) , [37](#)).

Предлагаемый метод разреженной идентификации нелинейной динамики (SINDy) зависит от выбора переменных измерения, качества данных и базиса разреженной функции. Не существует единого метода, который решит все проблемы в идентификации нелинейной системы, но этот метод подчеркивает важность этих базовых выборов и может помочь в руководстве анализом. Проблемы выбора переменных измерения и базиса разреженной функции рассматриваются в [Приложении SI](#) , разделе 4.5 и Приложениях [A](#) и [B](#).

Проще говоря, нам нужны правильные координаты и базис функций для получения разреженной динамики; осуществимость и гибкость этих требований обсуждаются в [Обсуждении](#) и [Приложении SI, раздел 4.5](#) и Приложениях [A](#) и [B](#). Однако может быть сложно знать правильные переменные априори. К счастью, координаты с задержкой по времени могут предоставить полезные переменные из временного ряда ([9](#) , [12](#) , [38](#)). Возможность реконструкции динамики разреженного аттрактора с использованием координат с задержкой по времени продемонстрирована в [Приложении SI, раздел 4.5](#), с использованием одной переменной системы Лоренца.

Выбор координат и разрежающий базис тесно связаны, и лучший выбор не всегда ясен. Однако базовые знания физики (например, уравнения Навье–Стокса имеют квадратичную нелинейность, а уравнение Шредингера имеет $|x|^2$ термины) могут обеспечить разумный выбор нелинейных функций и координат измерения. Фактически, разреженность и точность предлагаемой разреженной идентифицированной модели могут предоставить ценную диагностическую информацию о правильных координатах измерения и основе, в которой следует представлять динамику. Выбор правильных координат для упрощения динамики всегда был важен, как показывают примеры лагранжевой и гамильтоновой механики ([39](#)). Все еще существует потребность в экспертах для поиска и использования симметрии в системе, и предлагаемые методы должны быть дополнены передовыми алгоритмами в машинном обучении для извлечения полезных признаков.

Результаты

Мы демонстрируем алгоритм на канонических системах [*](#) , начиная от линейных и нелинейных осцилляторов ([Приложение SI, раздел 4.1](#)), до шумных измерений хаотической системы Лоренца, до нестационарного жидкого следа за цилиндром, расширяя этот метод на нелинейные уравнения в частных производных и многомерные данные. Наконец, мы показываем, что параметры бифуркации могут быть включены в модели, восстанавливая параметризованную логистическую карту и нормальную форму Хопфа из шумных измерений. В каждом примере мы исследуем возможность идентификации динамики только из измерений состояния, без доступа к производным.

Важно повторить, что метод разреженной идентификации опирается на удачный выбор координат и функционального базиса, которые облегчают разреженное представление динамики. В [Приложении SI, Приложении B, мы исследуем ограничения метода на примерах](#) , где эти предположения не выполняются: система Лоренца, преобразованная в нелинейные координаты, и модель гликолитического осциллятора ([11-13](#)).

Хаотическая система Лоренца.

В качестве первого примера рассмотрим каноническую модель хаотической динамики, систему Лоренца ([40](#)):

$$\dot{x} = \sigma(y - x), \quad [7a]$$

$$\dot{y} = x(\rho - z) - y, \quad [7b]$$

$$\dot{z} = xy - \beta z. \quad [7c]$$

Хотя эти уравнения порождают богатую и хаотическую динамику, которая развивается на аттракторе, в правой части уравнений есть только несколько членов. [На рис. 1](#) показана схема того, как собираются данные для этого примера, и как разреженная динамика идентифицируется в пространстве возможных правых функций с использованием выпуклых ℓ_1 минимизация.

В этом примере данные собираются для системы Лоренца и объединяются в две большие матрицы данных. $\mathbf{X}$ и $\dot{\mathbf{X}}$, где каждая строка $\mathbf{X}$ это моментальный снимок состояния $\mathbf{x}$ со временем, и каждая строка $\dot{\mathbf{X}}$ это моментальный снимок производной по времени состояния $\dot{\mathbf{x}}$ во времени. Здесь правая динамика определяется в пространстве полиномов $\Theta(\mathbf{X})$ в (x, y, z) до пятого порядка, хотя другие функции, такие как $\sin, \cos, \exp$ или могут быть включены полиномы более высокого порядка:

$$\Theta(\mathbf{X}) = \begin{bmatrix} x(t) & y(t) & z(t) & x(t)^2 & x(t)y(t) & \cdots & z(t)^5 \end{bmatrix}.$$

Каждый столбец $\Theta(\mathbf{X})$ представляет собой функцию-кандидата для правой части [уравнения 1](#). Поскольку только несколько из этих членов активны в каждой строке $\mathbf{f}$, мы решаем задачу разреженной регрессии в [уравнении 3](#), чтобы определить разреженные векторы коэффициентов $\Xi = [\xi_1 \ \xi_2 \ \cdots \ \xi_n]$ которые определяют, какие термины активны в динамике. Это схематически показано на [рис. 1](#) , где разреженные векторы ξ_k обнаружено, что представляют собой производную $\dot{x}_k$ как линейная комбинация наименьшего количества членов в $\Theta(\mathbf{X})$.

В примере Лоренца способность улавливать динамику на аттракторе важнее, чем способность предсказывать индивидуальную траекторию, поскольку хаос быстро приведет к тому, что любые небольшие изменения в начальных условиях или коэффициентах модели будут расходиться экспоненциально. Как показано на [рис. 1](#) ,

разреженная модель точно воспроизводит динамику аттрактора из измерений хаотической траектории. Алгоритм не только идентифицирует правильные члены в динамике, но и точно определяет коэффициенты с точностью до 0,03% от истинных значений. Мы также исследуем идентификацию динамики, когда доступны только измерения зашумленного состояния ([Приложение SI, рис. S7](#)). Правильная динамика идентифицируется, и аттрактор сохраняется для удивительно больших значений шума. В [Приложении SI, разделе 4.5](#) , мы реконструируем динамику аттрактора в системе Лоренца, используя координаты с задержкой по времени из одного измерения $x(t)$.

PDE для вихреобразования за препятствием.


Система Лоренца — это низкоразмерная модель более реалистичных высокоразмерных моделей PDE для конвекции жидкости в атмосфере. Многие интересующие нас системы управляются PDE ([24](#)), например, погода и климат, эпидемиология и энергосистема, и это лишь некоторые из них. Каждый из этих примеров характеризуется большими данными, состоящими из больших пространственно разрешенных измерений, состоящих из миллионов или миллиардов состояний и охватывающих порядки величины масштаба как в пространстве, так и во времени. Однако многие высокоразмерные системы реального мира развиваются на низкоразмерном аттракторе, что делает эффективную размерность намного меньше ([35](#)).

Здесь мы обобщаем метод SINDy на примере в динамике жидкости, который типично иллюстрирует многие из проблем, описанных выше. В контексте данных из PDE наш алгоритм разделяет некоторые связи с разложением динамической моды, которое является линейной динамической регрессией ([41–43](#)) . Данные собираются для потока жидкости мимо цилиндра при числе Рейнольдса [100](#) с использованием прямого численного моделирования двумерных уравнений Навье–Стокса ([44](#) , [45](#)). Нелинейная динамическая связь между доминирующими когерентными структурами определяется из этих измерений поля потока без знания управляющих уравнений.

Поток, проходящий мимо цилиндра, является особенно интересным примером из-за его богатой истории в механике жидкости и динамических системах. Долгое время предполагалось, что турбулентность является результатом серии бифуркаций Хопфа, которые происходят по мере увеличения скорости потока ([46](#)), приводя к появлению более богатых и сложных структур в жидкости. Спустя 15 лет была обнаружена первая бифуркация Хопфа в жидкой системе при переходе от устойчивого ламинарного следа к ламинарному периодическому вихреобразованию при числе Рейнольдса 47 ([47](#) , [48](#)). Это открытие привело к давним дебатам о том, как бифуркация Хопфа с кубической нелинейностью может быть продемонстрирована в жидкости Навье–Стокса с квадратичными нелинейностями. Еще через 15 лет эта проблема была решена с помощью разделения временных масштабов и модели среднего поля ([49](#)), показанной в [уравнении 8](#) . Было показано, что связь между колебательными модами и базовым потоком приводит к возникновению медленного многообразия ([рис. 2, слева](#)), что

приводит к алгебраическим членам, которые аппроксимируют кубические нелинейности на медленных временных масштабах.

Рис. 2.



Пример высокоразмерной динамической системы из динамики жидкости. Срыв вихря мимо цилиндра является прототипическим примером, который используется для управления потоком, что имеет отношение ко многим приложениям, включая снижение сопротивления позади транспортных средств. Срыв вихря является результатом бифуркации Хопфа. Однако, поскольку уравнения Навье–Стокса имеют квадратичную нелинейность, необходимо использовать модель среднего поля с разделением временных масштабов, где быстрая деформация среднего поля подчиняется медленной динамике срыва вихря. Показано параболическое медленное многообразие (слева) с неустойчивой неподвижной точкой (C), средним потоком (B) и срывом вихря (A). Базис POD и режим сдвига используются для уменьшения размерности задачи (в середине справа). Выявленная динамика близко соответствует истинной траектории в координатах POD, и, что наиболее важно, они охватывают квадратичную нелинейность и временные масштабы, связанные с моделью среднего поля.

Этот пример представляет собой убедительный тестовый пример для предлагаемого алгоритма, поскольку экспертам сообщества потребовалось почти три десятилетия, чтобы раскрыть базовую форму динамики. Поскольку размерность состояния велика и состоит из жидкого состояния в сотнях тысяч точек сетки, сначала необходимо уменьшить размерность системы. POD (35, 37) обеспечивает низкоранговую основу, что приводит к иерархии ортонормированных мод, которые при усечении захватывают большую часть энергии исходной системы для заданного усечения ранга. Первые две наиболее энергичные моды POD захватывают значительную часть энергии, а стационарное вихревое сбрасывание является предельным циклом в этих координатах. Дополнительный режим, называемый сдвиговым режимом, включен для захвата переходной динамики, связывающей нестабильное стационарное состояние («C» на рис. 2) со средним значением предельного цикла (49) («B» на рис. 2). Эти режимы определяют x, y, z координаты на рис. 2.

В описанной выше системе координат модель среднего поля для динамики цилиндра задается выражением (49)

$$\dot{x} = \mu x - \omega y + Axz, \quad [8a]$$

$$\dot{y} = \omega x + \mu y + Ayz, \quad [8b]$$

$$\dot{z} = -\lambda (z - x^2 - y^2). \quad [8c]$$

Если λ велико, так что динамика z быстрая, то средний поток быстро корректируется, попадая на (медленный) коллектор $z = x^2 + y^2$ заданной амплитудой вихревого срыва. При подстановке этого алгебраического соотношения в [уравнения 8a](#) и [8b](#) мы восстанавливаем нормальную форму Хопфа на медленном многообразии.

С историей этих трех координат предложенный алгоритм правильно идентифицирует квадратичные нелинейности и воспроизводит параболическое медленное многообразие. Обратите внимание, что производные измерения недоступны, но вычисляются из переменных состояния. Интересно, что когда данные обучения не включают траектории, которые исходят из медленного многообразия, алгоритм неправильно идентифицирует кубические нелинейности и не может идентифицировать медленное многообразие.

Нормальные формы, бифуркации и параметризованные системы.

На практике многие реальные системы зависят от параметров, и при изменении параметра могут происходить существенные изменения или бифуркации. Алгоритм SINDy легко расширяется для охвата этих важных параметризованных систем, позволяя обнаружить нормальные формы ([31](#), [50](#)), связанные с параметром бифуркации μ . Сначала мы добавляем μ к динамике:

$$\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}; \mu), \quad [9a]$$

$$\dot{\mu} = 0. \quad [9b]$$

Тогда можно будет идентифицировать $\mathbf{f}(\mathbf{x}; \mu)$ как разреженное сочетание функций $\mathbf{f}$ и также параметр бифуркации μ .

Определение параметризованной динамики показано на двух примерах: одномерная логистическая карта со стохастическим воздействием,

$$x_{k+1} = \mu x_k (1 - x_k) + \eta_k,$$

и двумерная нормальная форма Хопфа ([51](#)),


$$\dot{x} = \mu x + \omega y - Ax(x^2 + y^2)$$

$$\dot{y} = -\omega x + \mu y - Ay(x^2 + y^2).$$

Логистическая карта представляет собой классическую модель динамики популяций, а нормальная форма Хопфа моделирует спонтанные колебания в химических реакциях, электрических цепях и неустойчивости жидкости.

Шумные измерения и разреженные динамические реконструкции для обоих примеров показаны на [рис. 3](#). В примере логистической карты стохастически вынужденная

траектория выбирается при 10 дискретных значениях параметров, показанных красным. Из этих измерений идентифицируется правильная параметризованная динамика. Параметризация достаточно точна, чтобы охватить каскад бифуркаций по мере увеличения μ , что приводит к подробной диаграмме бифуркации на [рис. 3](#). Параметры идентифицируются с точностью до 0,1% от истинных значений ([Приложение SI](#), [Приложение C](#)).



В примере нормальной формы Хопфа шумные измерения состояния из восьми значений параметров отбираются с данными, собранными по синей и красной траекториям на [рис. 3](#) (сверху справа). Шум добавляется к измерениям положения для имитации шума датчика, и используется регуляризованная производная общей вариации ([33](#)). В этом примере нормальная форма правильно идентифицирована, что приводит к точным предельным амплитудам цикла и темпам роста (снизу справа). Правильная идентификация нормальной формы критически зависит от выбора переменных и нелинейных базисных функций, используемых для $\Theta(\mathbf{x})$. На практике эти решения могут приниматься на основе машинного обучения и анализа данных, частичного знания физики и экспертной человеческой интуиции.

Аналогично, зависимость от времени и внешнее воздействие или управление с обратной связью $\mathbf{u}(t)$ может быть добавлено к векторному полю:

$$\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \mathbf{u}(t), t),$$

$$\dot{t} = 1.$$

Обобщение алгоритма SINDy позволяет анализировать системы, которые подвергаются внешнему воздействию или контролируются. Например, климат одновременно параметризован ([50](#)) и имеет внешнее воздействие, включая углекислый газ и солнечную радиацию. Финансовый рынок — еще один важный пример с воздействием и активным управлением обратной связью.

Обсуждение

Подводя итог, мы продемонстрировали мощный метод идентификации нелинейных динамических систем из данных без предположений о форме управляющих уравнений. Это основано на предыдущей работе в символической регрессии, но с инновациями, связанными с разреженной регрессией, которые позволяют нашим алгоритмам масштабироваться до многомерных систем. Мы демонстрируем этот метод на ряде примеров систем, демонстрирующих хаос, многомерные данные с низкоранговой когерентностью и параметризованную динамику. Как показано в примере Лоренца, способность предсказывать определенную траекторию может быть менее важна, чем способность улавливать динамику аттрактора. Пример из динамики жидкости подчеркивает замечательную способность этого метода извлекать динамику в жидкой системе, на объяснение которой экспертам в сообществе потребовалось три десятилетия. Существует множество областей, где может применяться этот метод, где есть достаточно данных и отсутствуют управляющие уравнения, включая нейронауку, климатологию, эпидемиологию и финансовые рынки. Наконец, нормальные формы могут быть обнаружены путем включения параметров в оптимизацию, как показано в двух примерах. Выявление разреженных управляющих уравнений и параметризаций знаменует собой значительный шаг на пути к давней цели интеллектуальной, самостоятельной идентификации динамических систем.

Мы продемонстрировали устойчивость алгоритма разреженной динамики к шуму измерения и недоступности производных измерений в примерах системы Лоренца ([Приложение SI, рис. S6 и S7](#)), логистической карты ([Приложение SI, раздел 4.4.1](#)) и нормальной формы Хопфа ([Приложение SI, раздел 4.4.2](#)). В каждом случае структура разреженной регрессии, по-видимому, хорошо подходит для шума измерения и процесса, особенно когда производные сглаживаются с использованием регуляризованной производной полной вариации.

Значительной нерешенной проблемой в вышеприведенном подходе является правильный выбор координат измерения и выбор базиса разреженной функции для динамики. Как показано в [Приложении SI, Приложении B](#) , алгоритм не может определить точную разреженную модель, когда координаты измерения и базис функции не поддаются разреженному представлению. В успешных примерах координаты и функциональные пространства каким-то образом были удачны в том, что они позволяли разреженное представление. Простого решения этой проблемы не существует, и должны быть скоординированные усилия по включению экспертных знаний, извлечения признаков и других передовых методов. Однако на практике может

быть некоторая надежда получить правильную систему координат и базис функции, не зная решения заранее, потому что мы часто знаем что-то о физике, которая управляет выбором функционального пространства. Неспособность определить точную разреженную модель также дает ценную диагностическую информацию о координатах и базисе. Если у нас мало измерений, их можно дополнить с помощью координат с задержкой по времени, как показано на системе Лоренца ([Приложение SI, раздел 4.5](#)). Когда измерений слишком много, мы можем извлечь когерентные структуры, используя уменьшение размерности. Мы также демонстрируем использование полиномиальных базисов для аппроксимации рядов Тейлора нелинейной динамики ([Приложение SI, Приложение A](#)). Связь между разреженной оптимизацией и динамическими системами, как мы надеемся, подстегнет разработки по автоматизации и улучшению этих выборов.

Наука о данных не является панацеей от всех проблем в науке и технике, но при правильном использовании она обеспечивает принципиальный подход к максимальному использованию имеющихся у нас данных и информированию о том, какие новые данные следует собирать. Большие данные появляются во всех науках, где данные по своей сути динамичны, а традиционные подходы склонны к переобучению. Алгоритмы обнаружения данных, которые создают экономичные модели, редки и желательны. Наука о данных станет еще более важной для усилий в области науки и техники, таких как понимание нейронной основы познания, извлечение и прогнозирование согласованных изменений климата, стабилизация финансовых рынков, управление распространением болезней и контроль турбулентности, где данных много, но физические законы остаются неуловимыми.

Благодарности

Мы благодарны за обсуждения с Бингом Брантоном и Берндом Ноаком, а также за содержательные комментарии рецензентов. Мы также благодарим Тони Робертса и Жана-Кристофа Луазо. SLB выражает признательность за поддержку Вашингтонскому университету. JLP благодарит Билла и Мелинду Гейтс за их поддержку Института моделирования заболеваний и спонсорскую помощь через Global Good Fund. JNK выражает признательность за поддержку Управлению научных исследований BBC США (FA9550-09-0174).

Вспомогательная информация

Приложение (PDF)

Вспомогательная информация

СКАЧАТЬ

13,47 МБ

Ссылки

1

MI Jordan, TM Mitchell, Машинное обучение: тенденции, перспективы и перспективы. *Science* **349**, 255–260 (2015).

↶

[Перейти к ссылке](#) | [Перекрестная ссылка](#) | [PubMed](#) | [Google Академия](#)

ПОКАЗАТЬ ВСЕ ССЫЛКИ

[ПОСМОТРЕТЬ ПОЛНЫЙ ТЕКСТ](#) | [СКАЧАТЬ PDF](#)

Дальнейшее чтение в этом выпуске

СТАТЬЯ ИССЛЕДОВАНИЯ | 24 МАРТА 2016 Г. | 

**Модуляция зарядового состояния
вакансии азота и флуоресценции в
наноалмазах с использованием
электрохимического потенциала**

Синан Каравели, Офир Гаатон, [...] Дирк Энглунд

ИССЛЕДОВАТЕЛЬСКАЯ СТАТЬЯ | 28 МАРТА 2016 Г. | 

**Дискретные события репликации
генов управляют связью между
клеточным циклом и циркадными
часами**

Йорис Пайманс, Марк Босман, [...] Дэвид К. Лубенски

ИССЛЕДОВАТЕЛЬСКАЯ СТАТЬЯ | 28 МАРТА 2016 Г. | 

**Доминирующие, открытые
невербальные проявления
привлекательны при нулевом
знакомстве**

Таня Вачаркульсемсук, Эмили Рейт, [...] Дэна Р. Карни

В тренде

[ИССЛЕДОВАТЕЛЬСКАЯ СТАТЬЯ](#) | 23 ДЕКАБРЯ 2024 Г. | 

Сравнение кооперативного решения геометрических головоломок муравьями и людьми

Коллективное познание часто упоминается как одно из преимуществ групповой жизни. Но какие факторы на самом деле способствуют групповому интеллекту? Чтобы ответить на этот вопрос, мы сравнили, как отдельные лица и...

[Табеа Дрейер](#), [Амир Халуц](#), [...] [Офер Файнерман](#)

[ИССЛЕДОВАТЕЛЬСКАЯ СТАТЬЯ](#) | 6 ЯНВАРЯ 2025 Г. | 

Высокие концентрации фторорганических соединений в городских сточных водах влияют на снабжение питьевой водой миллионов американцев

Муниципальные сточные воды США являются основными источниками пер- и полифторалкильных веществ (ПФАВ), которые, как известно, влияют на качество питьевой воды. Среди восьми крупных очистных сооружений с...

[Бриджер Дж. Руйл](#), [Эмили Х. Пеннойер](#), [...] [Элси М. Сандерленд](#)

PDF

Помощь

Телесные карты эмоций

Эмоции координируют наше поведение и физиологические состояния во время событий, важных для выживания, и приятных взаимодействий. Хотя мы часто осознаем наше текущее эмоциональное состояние, например, гнев или...

Лаури Нумменмаа, Энрико Глереан, [...] Яри К. Хиетанен

Подпишитесь на
Информационный бюллетень PNAS
Highlights

Получайте подробные научные статьи на свою электронную
почту дважды в месяц.

имя@example.com

ПОДПИСАТЬСЯ >

ПРОСМАТРИВАТЬ

ТЕКУЩИЙ НОМЕР

PNAS НЕКСУС

ОСОБЫЕ ВОЗМОЖНОСТИ

СПИСОК ПРОБЛЕМ

СОБРАННЫЕ СТАТЬИ

PNAS В НОВОСТЯХ

ПЕРЕДОВАЯ ЧАСТЬ

ЖУРНАЛ КЛУБА

МУЛЬТИМЕДИА

ПОДКАСТЫ



ИНФОРМАЦИЯ

- О
- РАЗНООБРАЗИЕ И ИНКЛЮЗИВНОСТЬ
- РЕДАКЦИОННАЯ КОЛЛЕГИЯ
- АВТОРЫ
- РЕЦЕНЗЕНТЫ
- ПОДПИСЧИКИ
- БИБЛИОТЕКАРИ
- НАЖИМАТЬ
- ПРЕМИЯ КОЦЦАРЕЛЛИ
- ОБНОВЛЕНИЯ PNAS

PDF

Помощь

